

四川大學

本科生毕业论文（设计）



题 目	音频增强系统啸叫智能检测与抑制方法		
学 院	计算机学院		
专 业	计算机科学与技术		
学生姓名	蒲晓阳		
学 号	2021141460201	年 级	2021 级
指导教师	冯文韬		

教务处制表

二〇二五年五月二十二日

音频增强系统啸叫智能检测与抑制方法

计算机科学与技术

学生 蒲晓阳 指导老师 冯文韬

【摘要】 在室内使用扩音系统时，声反馈现象在某些条件下会导致音频在某些频率点出现正反馈，引发啸叫。现有的啸叫抑制技术主要是依赖啸叫检测和自适应估计的传统算法方案，这些方案或多或少会破坏信号的质量。而随着深度学习技术在声学领域的应用扩大，为了探索该技术在声学啸叫抑制问题上的潜力，本文对使用神经网络应用于啸叫领域的方案进行研究。本文将啸叫抑制过程以语音分离的思想进行抽象简化，提出了一种利用傅里叶变换获得的复数矩阵特征和基于 MLP 和 RNN 网络架构的啸叫抑制模型方案，从麦克风信号中提取出目标信号，抑制了可能引发啸叫的反馈信号。通过建立数学啸叫模型，模拟生成数据，设计特征提取工程等工作，选用不同的技术组合，包括输入特征，模型和激活函数等，通过实验选用合适的组合进行验证分析，得到了使用 RNN 较优参数的模型方案。通过该模型进行推理，比对分析图像数据，可以发现所提出的方案明显的消除了啸叫信号，验证了深度学习方案的可行性。但所提出的方案在声音质量效果上仍然需要提升。

【关键词】 音频增强系统、啸叫抑制、啸叫模型建模、深度学习

Intelligent detection and suppression method for howling in audio enhancement system

Computer Science and Technology

Student: PU Xiao-yang **Adviser:** FENG Wen-tao

[Abstract] When using an audio enhancement system indoors, acoustic feedback can cause positive feedback at certain frequencies, resulting in howling under certain conditions. Existing howling suppression techniques mainly rely on traditional algorithm approach with howling detection and adaptive estimation, which can damage the quality of the signal. With the expansion of deep learning technology in the field of acoustics, to explore the potential of this technology in acoustic howling suppression, this paper studies the application of neural networks in the howling field. This article abstracts and simplifies the process of howling suppression based on the idea of speech separation and proposes a howling suppression model scheme that utilizes complex matrix features obtained from Fourier transform and network architectures with MLP and RNN to extract target signals from microphone signals and suppress feedback signals which maybe cause howling. By establishing a mathematical howling model, simulating data generation, designing feature extraction engineering, and selecting different combinations of techniques, which include input features, models, and activation functions, appropriate combinations were selected through experiments for verification and analysis, a model scheme using RNN with optimal parameters was obtained. By using this model for inference and comparing and analyzing image data, it can be found that the proposed solution significantly eliminates howling signals, verifying the feasibility of the deep learning approach. But the proposed solution still needs to be improved in terms of sound quality.

[Key Words] Audio enhancement system、Howling suppression、Howling modeling、Deep learning

目录

1. 绪论	1
1.1 研究背景与意义	1
1.2 国内外研究现状	2
1.3 研究内容与结构安排	3
2. 相关理论基础	5
2.1 声学啸叫的理论模型	5
2.2 深度学习的理论基础	6
2.2.1 多层感知机	6
2.2.2 循环神经网络	8
2.2.3 激活函数	9
2.3 音频信息提取技术	12
2.3.1 语音的信号表征	13
2.3.2 傅里叶变换	15
2.3.3 短时傅里叶变换 (STFT)	16
3. 实验设计	18
3.1 数据集构建	18
3.2 采用的方法	19
3.2.1 特征提取	19
3.2.2 模型结构	20
3.3 评价指标	21
4. 实验组织	23
5. 实验结果	24
5.1 实验数据记录	24
5.1.1 激活函数实验结果	24

5.1.2 帧长实验结果	24
5.2 实验数据分析	25
5.3 啸叫抑制效果	26
6. 结语	29
6.1 总结工作	29
6.2 下一步工作与展望	29
参考文献	31

1. 绪论

1.1 研究背景与意义

声音是信息传递的常见媒介之一，随着声音在信息传递中的广泛应用，扩音系统成为了确保信息在各类场景下正常传递的重要工具，广泛使用于学校、体育场、教室、商场等场景^{[1][2]}。然而，扩声系统在室内使用时，由于扬声器和麦克风处于同一声场，目标信号由放大器放大后，经过空间的反射传播后被麦克风重新拾取，形成声学回路，在特定情况下，反馈信号与目标信号的耦合会形成一个正反馈闭环回路。如果该系统中某个频率的信号在这一闭环回路中满足奈奎斯特稳定准则，即环路增益大于等于 1 且相位满足正反馈条件，在这种情况下，该频率的信号就会不断放大，形成自激振荡^[6]，最终产生刺耳的啸叫声。啸叫现象不仅严重影响听觉体验，还会对音响设备等器件造成不可逆的损坏，这限制了扩音系统的性能和应用场景。

因此，研究扩音系统的啸叫智能检测与抑制方法具有重要的现实意义。从上世纪发展到现在，啸叫抑制（AHS）技术经历了从人工干预到模拟电路控制，再到电子自动控制的发展历程。目前的技术主要分为硬件方案和软件方案：其中硬件方案更多是通过优化麦克风和音响的布局与设计来减少啸叫的发生；而软件方案则通过使用：移频/移相^[7]、陷波抑制^{[8][9]}和自适应反馈抑制算法^[10]等手段实现。尽管这些技术已经广泛应用于扩音系统，但是随着人们对系统鲁棒性和音质要求的不断提高，现有技术仍暴露出了诸多不足。例如，陷波抑制其需要对啸叫点进行精确的检测，并且会扭曲目标音频，甚至引入新的啸叫频率点^[3]。自适应反馈抵消通过自适应滤波器来估计扩音器和麦克风的声学路径来抑制啸叫，但由于目标信号和反馈信号的高度相关，滤波器需要使用去相关技术，这会导致语音质量降低^[4]。

近年来，人工智能技术的快速发展为啸叫抑制方案提供了新的思路。基于深度学习的音频处理技术快速发展，尤其是以 transformer 为代表的深度神经网络，在许多领域都表现处理良好的性能。其次，神经网络在音频领域的迁移应用方案逐渐增多，包括但不限于音频分离，语音识别领域等，在某些领域中，神经网络的表现已经超过了传统方案。这样的情况下，在啸叫领域中使用深度学习技术来突破传统解决方案的局限性有了可能。鉴于深度学习在处理复杂的非线性关系方面具有强大的能力，通过建立啸叫信号与干净信号之间的映射关系^[5]，深度学习方法有望能够高效地去除啸叫分量，同时减少原始信号的失真。此外，深度学习技术具有自适应性强、扩展性好等特点，能够更好地适应不同场景下的啸叫抑制需求。因此，我们将其视作解决声学啸叫抑制问题的有效方案。本研究能为声学啸

叫抑制技术的发展提供新的理论和实践参考，推广扩音系统在教育、会议、场馆等场景中的应用，提升用户的体验，保护设备。

1.2 国内外研究现状

在上世纪年代，啸叫抑制主要使用人工干预手段^[3]，通过专业音频人员手动调整均衡器来降低啸叫频点的增益，或者通过改变增益系统的布局，比如改变麦克风和扬声器位置，使用定向麦克风等方法来减少声反馈。这种方法需要专业人员操作，且成本较高，难以实时应对啸叫的产生。近几年，数字信号处理的发展推动了软件控制，自动软件控制逐渐取代了手动控制。这些方法通过自动化的算法来检测和抑制啸叫，无需人工干预。根据时间年代，本部分将简单介绍下几种自动化控制的啸叫抑制方案：

相位调制法^[7]：最早出现的自动控制方法之一，包括移频（FM）和移相（PM）方法。通过改变信号的频率和相位来破坏啸叫产生的相位条件，从而抑制啸叫。虽然该方法简单易实现，但这类对信号进行移动的操作会导致信号失真，对音质影响较大，因此其应用场景受限。

增益控制法^[8]：该方法通过降低系统增益来减少啸叫音频的强度。包括自动增益控制（AGC）和自动均衡控制（AEQ）。AGC 方案是在系统检测到啸叫时自动降低整个信号的增益，该方法简单，容易实现，但会影响整体信号的强度和质量，尤其是在大空间中，这种影响会更加明显。AEQ 则是通过将音频信号分为多个频带，针对啸叫的特定频段进行增益控制，这种方法能减少对非啸叫的频段的影响，从而在一定程度上保持音质。在此之上，陷波器法（NHS）则是使用了陷波器这一特化的物理设备，其能对产生啸叫的特定频率点进行抑制，从而消除啸叫。相较于 AEQ，NHS 法对啸叫点进行了更加精确（频带更窄）的检测和抑制，但这会使得陷波器的性能很大程度上是依赖于其内部的啸叫检测算法的准确度和速度。

自适应声反馈抵消法^{[2][10]}：（AFC）是目前较为先进的啸叫抑制技术之一。该方法通过自适应滤波器对声反馈路径进行估计建模，从而从输入信号中去除声反馈信号，达到抑制啸叫的目的。理论上，反馈路径若能完美的被估计出来，那么反馈信号就能被完全消除（实际无法做到），所以自适应滤波器的性能则取决与其路径估计算法。一开始，最小均方误差（LMS）和归一化最小均方误差（NLMS）被广泛应用与其中。而近些年中，更多的改进的自适应算法例如变长 LMS 算法被提出，提高自适应算法的收敛速度和稳定性。但该方法也不可避免地降低了音质^[10]。

其次，深度学习技术在语音领域的应用已经十分的广泛了，在各类问题中都有不输于传统方法的效果。例如语音增强，研究人员将增强任务建模成一种将带噪语音中的目标语

音提取出来，减少信号的噪声成分的任务。另外在语音识别中，深度学习也被应用在语音的匹配和识别之中，大大增强了语音识别的能力。语音分离则和语音增强有着相似的特性，同样是从混合的语音中提取出目标语音。针对这类问题，许多研究员都提出了使用深度学习的方法来钻研语音领域。而啸叫也和语音分离有着相似之处，所以许多关于语音分离的任务和模型都可以迁移到此类方案中来。

1.3 研究内容与结构安排

鉴于现阶段中使用深度学习技术来解决声学啸叫的方案并不多，而在抑制声学回声（AEC）等领域中，深度学习技术的方案已经被成功引入^{[11][12][13]}，考虑到啸叫抑制的目标是衰减反馈信号，只发送目标信号，这与 AEC 领域的技术细节相似。因此我们有理由认为深度学习技术也可以被应用于解决声学啸叫抑制（AHS）领域中。

本文将尝试应用深度学习技术去解决啸叫抑制问题^[14]，我们将尝试把 AHS 表述为一类监督学习问题，问题的总体目标是在抑制麦克风录音中的反馈信号，只保留目标源信号。将啸叫信号与干净信号之间的映射关系通过神经网络模型来进行训练学习。并最终预测推理出目标信号（即干净信号）本文研究的内容主要包括以下几点：1. 我们将 AHS 描述为在深度学习框架下的有监督学习问题，这个想法与传统方法有很大的不同，不需要进行啸叫点检测，能避免由啸叫点检测而带来的开销。2. 通过论证理论模型来说明本文研究思路。3. 通过对比不同的模型和性能结果比较来说明深度学习技术应对啸叫抑制问题的可行性。

本文的结构安排如下所示：

第一部分是引言部分，首先介绍了研究的背景意义，描述了啸叫的现象和其影响，研究 AHS 技术的现实意义等，再依据发展历史简单介绍了几类传统的 AHS 方案说明了相关特点和其优缺点，最后简单概括了内容和结构。

第二部分介绍相关的理论基础，首先是啸叫的理论模型：通过分析啸叫产生原理，建立啸叫数学模型，为后续研究提供理论基础。再者介绍了深度学习的理论基础：MLP, RNN 等神经网络的数学理论模型，最后简单介绍了激活函数的使用。最后提及了音频处理技术，主要是傅里叶变换及其实现原理，为特征提取工程的进行铺垫了理论。

第三部分主要介绍实验使用的技术思路 and 方案，包括数据集的构建工作，啸叫的模拟仿真细节等。介绍了特征提取工程的具体实现流程，网络结构的定义等。

第四部分主要介绍实验环境的搭建以及具体的实验步骤，同时对实验数据结果进行处理分析，采用不同的方法对实验进行的影响。

第五部分分析和讨论了第四部分进行实验组织后得到的实验结果，呈现了实验的关键数据和图表，对实验结果进行详细的分析和讨论，总结实验中发现的问题和不足。

第六部分为本文的工作进行了总结，概况了该技术在 AHS 领域的应用潜力。同时，对以后的工作内容提出了展望和建议，为后续工作提供参考。

2. 相关理论基础

2.1 声学啸叫的理论模型

在不失普遍性的前提条件下，我们可以抽象出一个典型的单通道闭环声学增益系统[5]，如下图所示，该系统由一个麦克风，功率放大器和扬声器组成，其中麦克风和扬声器耦合




图 1：单通道闭环声学增益系统

在一个空间内。在图中， $s(t)$ 表示为目标源信号， $d(t)$ 表示为扬声器的反馈信号。麦克风采样源信号和反馈信号，得到麦克风输出信号 $y(t)$ ，输出信号经过功率放大器 G 进行声学放大后传输到扬声器，扬声器通过播放将电信号转换为声场中的声音信号，即扬声器输出信号 $x(t)$ 。输出信号经过反馈声学路径 $h(t)$ 获得反馈信号，记作 $d(t)$ ：

$$d(t) = NL[x(t)] * h(t) \quad (2.1)$$

其中 $NL(.)$ 表示扬声器引入的非线性失真， $h(t)$ 表示从扬声器到麦克风的声学路径， $*$ 表示线性卷积。如果不进行啸叫抑制，则扬声器输出信号 $x(t)$ 则是 $y(t)$ 经过延迟和放大的版本，则反馈信号可以表示为：

$$d(t) = NL[y(t - \Delta t) \times G] * h(t) \quad (2.1)$$

其中 Δt 表示从麦克风到扬声器的系统延迟， G 表示功率放大器的增益。而反馈信号 $d(t)$ 则会反复进入麦克风，对应时间 t 时刻的相应麦克风信号可以表示为：

$$y(t) = s(t) + NL[y(t - \Delta t) \times G] * h(t) \quad (2.3)$$

由此可见， $y(t)$ 和 $y(t - \Delta t)$ 之间的递归传递关系会导致反馈信号的重合，形成正反馈。导致信号在某些频率下的循环放大，即产生声学啸叫^[14]。需要了解的是，啸叫是不断反馈导致的，不是瞬间产生的，其以多个反馈信号的融合开始，在放大到一定程度后才会形成尖锐的声音（虽然啸叫产生的过程可能很快）。导致啸叫的反馈信号和目标信号的产生源头是相同的，而在声学回声领域里，回声通常产生自不同的源^[12]，因此啸叫的抑制更具有挑战性。

2.2 深度学习的理论基础

随着深度学习理论的进步和并行计算能力的快速提升，神经网络结构变得越发复杂，而随着神经网络的深度（层数）和广度（单层的神经元数）的提升，神经网络能够学习到数据中隐含的复杂模式和非线性关系。实验将使用到深度学习的模型技术，本部分将简单介绍两种经典的深度神经网络模型：多层感知机（MLP）和循环神经网络（RNN）。分析两种网络的结构，原理，和适用场景等，再简单介绍下深度学习训练的激活函数。为之后的网络结构设计方面提供理论基础。

2.2.1 多层感知机

深度学习技术突破了传统算法的线性限制，使得神经网络能够处理更加普遍和复杂的关系，经过多年的发展，越多越复杂的网络架构被提出，而其中最基础，最简单的网络就是将传统线性层堆叠起来，将前一层的输出作为下一层的输入，输出接输入直到生成最后的结果，这样的架构通常被称作多层感知机，也被缩写为 MLP。这是一种典型的前馈神经网络，由输入层，隐藏层（一层或多层）以及输出层三大部分构成，为了更加直观清楚的理解多层感知机的架构，下面将通过绘制神经元连接图方式，展示各层之间的连接关系和信息传递链，以便更好的把握网络的全貌：




图 2：单隐藏层的多层感知机

图中的感知机中有四个输入，三个输出，其中的单隐藏层包含五个隐藏单元。每个神经元通过权重与前一层的所有神经元相连。输入层不涉及计算，用于接受数据，隐藏层提取特征，输出层生成结果。层与层之间进行全连接，每个输出神经元都会影响其后的所有神经元。

MLP 通过前向传播和反向传播算法进行训练。在前向传播的过程中，输入数据通过每层神经元，经过权重矩阵的线性变换和激活函数的非线性变换后，最终在输出层得到预测结果。

为了在数学形式上对 MLP 有更好的理解，我们将假设有小批量（ n 数量样本）的输入 $X \in R^{n \times d}$ ，其中每个样本有大小为 d 的输入特征，使用一个具有 h 大小的隐藏单元的单隐藏层的多层感知机来演示，用 $H \in R^{n \times d}$ 表示隐藏层的输出，在代码里， H 也被称为隐藏层变量，由全连接可知隐藏层的权重 $W^{(1)} \in R^{d \times h}$ 和隐藏层偏置 $b^{(1)} \in R^{1 \times h}$ 和 输出层权重 $W^{(2)} \in R^{h \times q}$ 和偏置 $b^{(2)} \in R^{1 \times q}$ ，因此我们计算该 MLP 的输出 $O^{(2)} \in R^{n \times q}$ 可以表示为以下公式：

$$\begin{aligned} H &= XW^{(1)} + b^{(1)} \\ O &= HW^{(2)} + b^{(2)} \end{aligned} \quad (2.4)$$

另一个额外的关键因素：即在线性变换之后对每个隐藏单元施加非线性的激活函数（ σ ）。激活函数的输出被称为活性值。激活函数是多层感知机处理非线性关系和防止网络退化的关键因素。

$$\begin{aligned} H &= \sigma(XW^{(1)} + b^{(1)}) \\ O &= HW^{(2)} + b^{(2)} \end{aligned} \quad (2.5)$$

MLP 一种早期经典的神经网络模型，应用广泛，即使其结构简单，在许多领域也都有较好的性能表现，所以许多研究都将其作为基础的实验性方案，因此本研究也将着手构建 MLP 架构作为实验方案之一。

2.2.2 循环神经网络

循环神经网络（RNN）的核心特点是能够通过“记忆”历史信息来处理前后关系依赖的循环单元。与传统的神经网络不同的是，RNN 的神经元之间形成了循环连接，允许信息在时间步间通过隐藏状态进行传递，得益于其网络结构的循环链接，RNN 类型的网络很擅长处理时序结构数据，所以其非常适合解决音频相关问题。

先介绍 RNN 的网络结构：RNN 是一种具有隐状态的神经网络，信息通过隐藏状态在时间步之间进行传递，每个时间步接收当前输入和前一时刻的隐藏状态，输出结果并更新隐藏状态，这样网络就能保存先前输入的信息，形成动态记忆。

在数学上，假设在时间步 t 时有小批量输入 $X_t \in R^{n \times d}$ ，用 $H_t \in R^{n \times d}$ 表示时间步 t 的隐藏变量，网络模型保存了前一时间步的隐藏变量 H_{t-1} ，引入了一个新的权重参数 $W_{hh} \in R^{n \times d}$ 来描述如何使用隐藏变量。具体而言， t 时刻的隐藏变量的计算公式为：

$$H_t = \sigma(H_t W_{xh} + H_{t-1} W_{hh} + b_h) \quad (2.6)$$

其中与全连接层的网络相比，多了一项隐藏层，这一层变量捕获了序列当前时间步的历史信息，就如同记忆一样，因此这类的隐藏变量被称为隐状态。由于在 t 时间中，隐状态与前一时间步 $t-1$ 的隐状态相关，因此是隐藏变量是循环计算的。于是这类基于循环计算的隐状态神经网络就被称为循环神经网络。在该网络中执行循环计算的层被称为循环层。

对于这样定义的网络，其输出层类似于多层感知机中的计算：

$$O_t = H_t W_{hq} + b_q \quad (2.7)$$

整个 RNN 的计算流程可以用以下的图表示：




图 3：具有隐状态的循环神经网络的计算流程

其中， ϕ 表示带有激活函数的全连接层，内部既包含了隐状态的变量参数 W_{hh} ，也包含了输出层的变量参数 W_{hq} 。

常见的变体 RNN 有门控循环单元（GRU）、长短记忆网络（LSTM）和双向 RNN 等。RNN 的优势在于直接建模序列的时序依赖关系，能够较好地处理时间序列相关问题。而音频是一种典型的时间相关序列信息，所以本研究也使用 RNN 来进行实验。

2.2.3 激活函数

激活函数是一种将输入信号转为输出信号的可微运算，通过计算输入值来确定该神经元是否应该被激活。大部分激活函数是非线性的，该特性确保了神经网络不会塌陷，为网络引入了非线性特征，使其能够学习到复杂的模式。可见激活函数是深度学习的基础，本部分将简单介绍一些常见的激活函数。

Sigmoid 函数：

其将定义域为 $\mathbb{R}$ 的数据变换为区间 $(0, 1)$ 之间的输出上，因此其也被称为压缩函数，其定义公式如下：

$$\text{Sigmoid}(x) = \frac{1}{1 + e^{-x}} \quad (2.8)$$

为了清楚了解函数特点，下面绘制 sigmoid 的函数图像，可以发现，当输入接近 0 时，该函数的图像接近线性变换：




图 4: Sigmoid 激活函数

在早期神经网络中，研究人员关注神经元的激发与否（阈值），而 sigmoid 因其平滑，可微，且与阈值单元相似，被广泛用于早期网络。但由于其计算开销较大，容易梯度消失等问题，不再作为网络首选。

ReLU 函数:

现在使用最为广泛的激活函数，线性修正单元（ReLU）因其实现简单，通过简单的非线性计算，模拟神经元的全有和全无特质，解决了传统激活函数的梯度消失问题，成为现代神经网络的核心组件，在现代神经网络中被广泛使用，定义如下：

$$ReLU(x) = \begin{cases} x, & x > 0 \\ 0, & x \leq 0 \end{cases} \quad (2.9)$$

简单来说，ReLU 函数通过将低于 0 的值的活性值设为 0，只保留大于 0 的元素。为了直观地了解该函数的特性，下面将画出该函数的曲线图，可以发现，该函数是分段的，其在 x 大于 0 的部分是呈现 $\pi/4$ 大小的直线，而在小于 0 的部分沿着横轴延伸：




图 5: ReLU 激活函数

ReLU 函数仅在正值区间内进行简单的线性运算，相较于 sigmoid 的需要进行的复杂指数运算，ReLU 函数大大提高了计算的速度，尤其在深层的神经网络结构中，这类简单的激活函数能有效的减少训练所需的时间和计算量的开销。其梯度简单的特点也能保证反向传播的有效性。

但是，ReLU 函数对于输入小于 0 的值来说，其输出恒为 0，这类输出会导致神经单元无法更新权重，类似死亡（Dead）的效果，这会影响网络的训练效果，除此之外，由于其输出的区间在 $[0, +\infty)$ 之间，这会导致下一层的神经元输入的数据分布发生偏移，这也会影响网络的训练稳定性和收敛的速度。

ELU 函数：

指数线性单元函数，ELU 的提出是为了解决 ReLU 的问题，与 ReLU 相比，ELU 有负值，使得激活函数的平均值接近 0，更接近自然的梯度，其定义如下：

$$ELU(x) = \begin{cases} \alpha(\exp(z) - 1), & x < 0 \\ x, & x \geq 0 \end{cases} \quad (2.10)$$

同样的，我们去绘制其图像，其中 α 值设为 1，可得到以下的函数图像：




图 6: ELU 激活函数

通过图像我们可以发现，ELU 通过部分增加曲线进行过度，使得其输出值平均跟接近 0，这使输出数据中心化，减少了训练偏移，有助于加速神经网络的训练过程；其次，其通过引入负数的指数函数，减轻了 ReLU 的神经元死亡问题，能更充分的利用神经元。其计算量介于 sigmoid 和 ReLU 之间，尽管理论上使用 ELU 会更好，但现在没有实验的充分证据能表明 ELU 总比 ReLU 好。

总结：激活函数的选择对于网络模型训练及优化比较重要，因此，选择了合适的激活函数，网络训练的收敛速度会比较快，效果也会比较好，所以我们会进行实验来根据相关因素选择合适的激活函数来训练网络。

2.3 音频信息提取技术

一方面，音频信息不同图片信息一样直观，对于在时空中连续的音频信息，在计算机中则是以离散的信息表示的，因此我们需要简单介绍下音频这一信息特点。另一方面，对于深度学习来说，特征提取是影响学习效果的关键部分，提取的特征需要能够良好的表征信号特性。一般而言，表现相同的性能的条件下，良好的特征提取能够适应复杂度低的模型，而性能更强大的模型对于特征提取的要求更低。所以，本部分有必要简单介绍各类音频的处理技术^[5]，在许多关于语音增强或语音分离的研究任务中，研究人员会使用短时傅

里叶变换提取语音的时频特征，再在此基础上获取其他特征，如均一化功率谱（LPS）或梅尔频率倒谱系数（MFCC）等。

2.3.1 语音的信号表征

物理的振动会引发空气中的分子相互挤压，形成声波，声波在空气中传播，速度一般是 340 米/秒。而声波是以引发空气中声压变化的形式进行传播的，这就引入了第一个表征声音的公式：

$$X(t) = A\sin(2\pi ft + \phi) \quad (2.11)$$

其中， $X(t)$ 表示随着时间 t 的变化而变化的声压， A 表示峰值声压，也指代振幅，表示声音的强弱响度，振幅越大，声音越响； f 表示频率，表示声波每秒振动的次数，是通过测得单位时间内完成的振动周期数，单位是赫兹（Hz）； ϕ 表示起始相位，相位表示了某个特定时间中音频信号到达的点位，对于一个周期来说，相位的值范围为 $(0 \sim 2\pi)$ ，相位通常是相对的值，例如我们说一个特定的时间 t 下，某纯音的相位相比于另一纯音的相位延迟 π 若前者处于波谷，那么后者就处于波峰。而上述中的初始相位是指在时间 $t=0$ 时刻中的位置，初始相位也是相对参考值，其参考的就是波形第一次经过 0 且在上升时的相位点。对于音频叠加来说，相位十分重要，不同声波的相位差会影响其叠加效果（增强或抵消）。这个函数表示了纯音在空气中传播的声压变化，其产生的波形是一种随着时间的推移而在正负值之间交替变化的。如下图是一个频率为 5Hz，峰值声压为 1，初始相位为 0，时长为 0.3s 的纯音图像表示：




图 7: ϕ 为 0, f 为 5Hz, A 为 1 的纯音表示

而在计算机中，声音则是以离散的数值形式表示的，声音以一定的采样率跟随时间不断被收音设备采取样本值，即时刻 n 的声压值。下图是将上图中的纯音以 100Hz 的采样率（sr）采样获得的离散波形图：




图 8：以 100Hz 进行采样获得的音频数据

因此，可以获悉声音信号在计算机中是以一段长度为 $n = sr \times t$ 大小的数值组合而成的，即以一维数组的形式存储。

另外，如果以声压或声强来直接表示声音的强度，则会出现巨大的数值范围，因为引发啸叫的最大声强往往是绝对听阈（能听到的最小声音）的声强的数亿倍。因此我们需要使用一种叫分贝（dB）的对数值来描述声音强度，而声强以分贝作为单位的表达形式被叫做声强级。公式如下：

$$\text{声级} = 10 \times \log_{10} \left(\frac{I}{I_0} \right) = 10 \times \log_{10} \left(\frac{P^2}{P_0^2} \right) \quad (2.12)$$

上式中， I 表示声强， I_0 表示标准参考声强，通常，空气中的参考声压是 $(2 \times 10^{-5} \text{W}/\text{MP}^2)$ ，其对应参考声强是 $(10 \sim 12 \text{W}/\text{M}^2)$ ，声级相较于该参考称为声压级（SPL）。对于和参考声压一致强度的声音，其值为 0dB SPL 。分贝 dB 以常数形式增加时其声压或声强则是以常量倍数形式倍增，所以在表征声音的放大或衰减时，分贝 dB 是十分直观的表达形式。

2.3.2 傅里叶变换

音频的原始表现形式（一维数组）时频信息，包含了其所有频率段的音频信息，为了将不同频率段上的音频分离出来，傅里叶变换技术被引入来将时域的音频转换为频域的信息表示。

傅里叶变换是一种数学变换，能够将复杂的信号函数分解为不同频率的信号组合，从物理意义上来说，傅里叶变换表征了信号的频率特征。将随时间变化的音频信号（时域中的一个复杂的波形）通过傅里叶变换后，就能了解频域上该信号包含的频率成分和其幅度和相位。在连续时空中，傅里叶（FT）的数学定义如下：

$$F(w) = \int_{-\infty}^{+\infty} X(t)e^{-iwt} dt \quad (2.13)$$

其中， f 表示频率， i 则是虚数单位，该式将时域信号函数 $X(t)$ 转换为频域信号 $F(w)$ 。由于在计算机中信息是以离散形式表现，所以傅里叶变换的离散形式（DFT）为：

$$F[k] = \sum_{n=0}^{N-1} X[n]e^{-i(2\pi/N)kn} \quad (2.14)$$

其对应的逆变换为：

$$X[n] = \frac{1}{N} \sum_{k=0}^{N-1} F[k]e^{i(2\pi/N)kn} \quad (2.15)$$

以上公式中， k 表示离散的频率值，而 n 则表示离散的时间点。从以上公式中可以看到，傅里叶变换使用的是整体时域信号，其逆变换使用的也是整体频域信号，也就是说，傅里叶变换是对信号进行整体变换的，这对于非时变（信号频率成分根据时间不变）的信号来说可以表征其频率成分，但是对于时变信号来说，使用傅里叶变换来分析信号是不合适的，而且大部分语音信号是时变信号，所以为了分析时变信号，研究人员提出了时频信息提取技术，时频信息包含了信号的时域和频域信息，简单来说，时频信息能表征信号随着时间进行其频率成分的变化形式，其表现形式是二维数组。为了得到时频信号，短时傅里叶变换被引入以满足需求。

在语音分离和语言增强等相关研究中，很多都使用短时傅里叶变换^[5]得到语言信号的时频复数矩阵或幅度矩阵，再将这些参数作为神经网络的输入特征进行训练。本研究也使用短时傅里叶变换技术来获得语言信号的特征数据，所以有必要介绍下短时傅里叶变换技术的原理和实现。

2.3.3 短时傅里叶变换（STFT）

STFT 是一种用于分析非平稳信号的时频分析方法，其通过将整个信号划分为多个小的时间段，并对每个时间段进行傅里叶变换来实现时频信息的局部变化表征。

STFT 的核心想法是使用一个窗函数（window）来将信号分割，每个短时信号被视作接近平稳的信号，窗函数的移动（hop）就能够获得信号在不同时间的频率信息。据此，STFT 就能够获得信号随着时间变化的频率变化。

假设信号为 $x(n)$ 时窗函数为 $\omega(n)$ 则短时傅里叶变换的定义为：

$$STFT(n, \omega) = \sum_{m=-\infty}^{+\infty} x(m)\omega(n-m)e^{-i\omega n} \quad (2.16)$$

随着 n 的移动，窗函数截取窗口大小信号，对该信号进行傅里叶变换来获得了一个 $STFT(n, \omega)$ 的时频函数。

使用窗函数时会产生频谱泄露，不同的窗函数会影响信号分析，常用的窗函数一般有两种，矩形窗和海明窗，因矩形窗会出现明显边界突变，出现大量泄露。所以一般选取海明窗（Hanning）作为窗函数，其主要特点是信号段两段边缘会缓慢减少信号强度以降低急剧变化的程度。

为了实现 STFT，我们需要将时域信号离散分割，首先将窗函数与时域信号组合，窗口宽度为 T 获得的每一段小的短信号可以表示为：

$$x(n, t) = x(t + nH)\omega(t), t \in (0, 1, \dots, T-1), n \in (0, 1, \dots, N-1) \quad (2.17)$$

其中， H 是相邻帧的移动步长（hop），为了保证帧与帧之间的信息连续性，其通常是帧长 T 的 $1/2$ 。 T 成为帧长，等价窗函数宽度， N 就是帧的数量。之后对每一帧信号使用离散傅里叶变换（DFT）获得时频特征 $F(n, f)$ 其表示形式是二维时频矩阵

$$\begin{bmatrix} F(0,0) & \dots & F(N-1,0) \\ \vdots & \ddots & \vdots \\ F(0,M-1) & \dots & F(N-1,M-1) \end{bmatrix} \quad (2.18)$$

其中的每个元素 $F(n, k)$ 表示第 n 帧，第 k 频率点的复数值，表示了幅度和相位。该矩阵一共有 M 行，表示共有 M 大小的频率点数；一共有 N 行，表示该信号一共有 N 帧。对该复数矩阵取绝对值则可以得到该信号的时频幅度矩阵。

由于神经网络无法直接输出时域信号，所以也需要将时频信号转换为时域信号的短时傅里叶逆变换（iSTFT）来进行信号重构，一般而言，使用 iSTFT 重构信号包含两个步骤，

首先对每帧信号进行傅里叶逆变换，再对得到的信息进行加权求和，以获得时域信号。一般 STFT 对应一个相似的 iSTFT，即相同的 FFT 长度，窗函数长度，窗函数类型，移动步长等。

相关研究中，不同的帧长度和不同的采样率，其对应的窗函数宽度也不一样，对于采样率为 16Khz 的信号（最常见）来说，语言长度选取 32ms 时，其对应的窗口宽度为 512 个点。窗口宽度同时决定了时频信号的时域分辨率和频域分辨率。为了研究方便，一般选取帧长为 16ms~32ms 长度的信号段来进行特征提取。

另外，选取不同的特征输入也会影响研究，本部分会介绍了两种类型的特征，一种是时频复数值谱，一种是时频幅度谱。需要注意的是，幅度谱丢失了相位信息，而对于信息重构（iSTFT）则需要信号的相位信息，因此在本实验中不使用幅度谱作为网络特征输入。

3. 实验设计

3.1 数据集构建

我们使用啸叫信号的时频特征作为神经网络的输入，但是开源的啸叫数据集几乎没有，而常见的语言数据集^[16]也不包含啸叫信息，为了获得啸叫信号，我们需要模拟：单通道闭环声学增益系统。通过第二部分的内容我们可以了解到啸叫信号的产生原理如此：由于原始输入信号和反馈信号的耦合，其中反馈信号由声反馈路径与扬声器信号卷积产生。公式如下：

$$d(t) = NL[y(t - \Delta t) \times G] * h(t) \quad (3.1)$$

声反馈路径可以使用房间脉冲响应生成器（RIR）模拟产生，使用图像法生成的脉冲响应（RIR）是最常用的，其中（RIR-generator）是一个基于 python 和 C 语言的开源库，用于合成房间脉冲响应，原本用于生成混响仿真。该项目是一个基于 Allen 和 Berkley 与 1979 年提出的图像法^[15]的代码实现，广泛用于声学处理领域，通过对房间尺寸，混响时间设置和麦克风位置等参数的设置，能够生成高度仿真的室内声学混响。

我们使用随机的房间特性（房间大小，麦克风和扬声器位置）和随机范围在（0.1~0.5）的混响时间（RT60）来生成 RIR，其表现形式为固定大小的音频函数，对于单通道的 RIR 来说，其形状大小是一维数组。另外，我们在生成数据期间也使用随机范围在（0.02~0.2）之间随机生成的系统延迟 Δt ，利用随机选择的 RIR 来生成目标语言对应的反馈信号 $d(t)$ 。最后的增益大小设置为 5~10dB 之间随机选择。

为了得到啸叫信号，我们需要模拟啸叫的信息流，在仿真中使用一段干净语言作为麦克风输入信号 $y(t)$ ，首先计算语言长度，再获取帧移（hop）大小的信号段，计算随机的时延长度 Δt ，遍历信号的所有信号段，从开始到结束，对每个信号段施加放大增益 G ，再引入非线性失真（主要是使用硬限幅函数和 Sigmoid 函数来模拟放大器的非线性失真），得到扬声器播放信号，再把生成的随机 RIR 引入，与播放信号进行卷积操作，生成反馈信号 $d(t)$ 。将 $d(t)$ 延时后叠加再下一刻要读取的原麦克风信号 $y(t)$ 上，依次往复，就能获得带有啸叫的信号 $y(t)$ 。

我们使用了来自 AISHELL-2^[16]的数据集样本，采样率为 16Khz，从中选取了低噪声和带有清晰语句的数据集，获得了 450 大小的样本作为训练验证数据集，50 大小的样本作为测试集。全部 500 样本中每条时长在 1s 到 10s 之间。其中测试集的 RIR 与验证集和训练集的 RIR 都不同，以保证测试的独立性。

3.2 采用的方法

首先，我们希望在理想状态下，AHS 方案能够完美地处理麦克风信号，即在发送到扬声器前完全衰减其中的反馈信号分量，如此情况下，啸叫便不会产生。那么 AHS 问题在语言分离^[12]的角度来看可以被视作一种语言分离问题，其中目标是需要从麦克风信号中分离出去原始信号。

据此，我们使用神经网络架构来训练一个用于啸叫抑制的模型^[14]。当模型经过训练后，应该衰减麦克风语言中的反馈信号，只向扬声器发送目标语言。这整个过程应该包括对信号进行特征提取，神经网络训练和预测的过程，对于本次研究，我们将使用基于复数矩阵的特征提取工程和基于 MLP 和 RNN 的模型训练和预测任务，

整个过程包含两大部件，即特征提取工程和网络架构设计部分^[5]，再者是两个流程，一个是训练流程，一个是预测推理流程。

3.2.1 特征提取

对于时域信号 $s(t)$ 对其进行 N 帧和 F 点的 STFT，则对于第 m 帧的信号的频谱表示如下：

$$S(m, f) = [(a_{f1} + b_{f1}i), \dots, (a_{fk} + b_{fk}i), \dots, (a_{fK} + b_{fK}i)] \quad k = 1, 2, \dots, K \quad (3.2)$$

上面公式中的 $(a_{f1} + b_{f1}i)$ 表示的是频率点的复数值，其绝对值表示的是幅度，角度表示的是频率的相位。由于 FFT 的对称性， $S(m, f)$ 中的频率点只取一半的数据^[5]。那么就有当 K 为偶数时， $N = K/2 + 1$ ， K 为奇数时， $N = (K+1)/2$ ，所以对于 FFT 长度为 256 的 STFT，其提取到的频率维度大小一般为 129。

因为复数值矩阵无法作为神经网络的输入，因此我们需要把每个频率点的实部和虚部取出重新组合形成一个新的值向量：

$$S_{mid}(m, f) = [a_{f1}, \dots, a_{fk}, \dots, a_{fN}, b_{f1}, \dots, b_{fk}, \dots, b_{fN}] \quad k = 1, \dots, N \quad (3.3)$$

这样变换后该向量的长度就变为了 $2N$ 长，若 K 为偶数时，其长度就是 $K+2$ ，若 K 为奇数时，其长度就是 $K+1$ ，该向量值的前半部分就是复值矩阵的实数部分，后半部分就是复值矩阵的虚数部分。

另外我们需要考虑声音信号的时间连续性，即当前帧的信号与相邻帧的信号关联性强，尤其与前向信号的关联性很强。因此在输入特征中加入前 L 帧的信息对于网络的效果会有

较好的提升。所以本研究会将当前帧和前 L 帧的特征向量组合叠加形成一个新的向量，将此向量作为神经网络的特征向量，即：

$$S_{in}(m, f) = [S_{mid}(m - L, f), \dots, S_{mid}(m, f)] \quad (3.4)$$

将啸叫信号的 $S_{in}(m, f)$ 向量作为神经网络的输入特征向量 X ，而相对应的使用干净语音的当前帧的向量 $S(m, f)$ 作为神经网络的期望输出 y 。

3.2.2 模型结构

作为基础研究方法，我们首先引入 MLP 模型，这一广泛应用的神经网络模型，对于 MLP，影响网络的主要因素包括隐藏层层数和每层的参数量。另外由于音频信号较强的时间连续性，我们也使用 RNN 模型来进行训练预测。以前 $L=3$ 帧为例，两种网络结构的参数如下：

表 1：帧长 L 为 3 时的 MLP 和 RNN 模型参数结构

网络	输入层	隐藏层	输出层
MLP	774	1000—600—500—400—300	258
RNN	3 * 258	两层 (2 * 600)	258

对于 MLP 而言，其输入层负责接收特征处理后的音频信息，需要包含幅度信息和相位信息等，中间层包括若干层全连接的线性层，通过激活函数引入的非线性特性使得网络能够学习到复杂模式，但全连接层所导致的参数过多会使得 MLP 的开销较大，效率低下，且有过拟合的风险。

本次实验所采用的 MLP 的结构细节有：

1. 激活函数统一使用一类激活函数，
2. 在第二层和第四层的输出层后接入 Dropout (0.2) 来随机剪裁网络以降低过拟合率。

对于 RNN 来说，其接受的特性向量序列能有效利用音频信号的时序特性，网络的隐藏层实现对于其至关重要，常用的 RNN 结构有 LSTM，GRU，再加上双向神经网络和深层循环网络结构，使得 RNN 能更好的处理时序信息。

本次实验的所采用的 RNN 结构细节主要有：

1. 初始化为 LSTM 网络，隐藏层数为 2，使用 dropout 技术防止过拟合。
2. 依据 LSTM 的来初始化隐藏变量，并根据网络结构更新全连接输出层的输入维度，以将 LSTM 的输出对应。

3. 前向传播的主要操作是将输入的 X 和初始状态 $state$ 传入 LSTM 网络，并得到对应的输出 out 和新的状态，注意这时的循环神经网络已经完成了所有时间步循环，因此输出 out 是和输入一个形状的向量，而我们只需要最后一个时间步的输出，所以我们取出最后一个时间步的输出，再通过全连接层传递到输出维度。

除了模型本身以外，为了提高模型收敛速度，防止梯度爆炸或消失等问题，在模型使用时会加上正则化技术和梯度剪裁。其中正则化是通过在损失函数中添加惩罚项或修改网络结构，降低模型复杂度，从而缓解过拟合，提升泛化能力的一种技术。常见的有 L1/L2 惩罚（损失函数中），Dropout（网络结构中，随机丢弃部分连接）Early Stopping 等。这些正则化技术都是通过某些手段降低模型复杂度，缓解过拟合，以期望模型在测试集中的性能更好，提高模型的鲁棒性。其次，梯度剪裁是在模型反向传播的过程中对梯度进行限幅或缩放等方法来缓解梯度爆炸问题，尤其是在 RNN 网络中，梯度剪裁能够限制梯度更新，防止数值溢出，从而保持模型训练的收敛稳定性。

3.3 评价指标

在数字化音频处理领域，我们需要准确地评估音频质量。无论是语音增强、语音分离，还是其他音频处理任务，研究都需要一套完善的评价指标体系来量化处理效果，为算法优化和系统改进提供依据。其中，尺度不变信噪比（SI-SDR）^[17]、语音质量感知评估（PESQ）^[18]和短时客观可懂度（STOI）^[19]这三种在音频质量评价在语音处理技术中广泛应用。

尺度不变信噪比（SI-SDR）：信号失真

尺度不变信噪比^[17]，即 SI-SDR，是一种专注于衡量语音强度与参考语音能量比例关系的指标，其同时规避了幅度差异所导致的影响。核心在于评估信号本身的失真程度，而非单纯受信号强度影响。在语音分离或增强场景里，SI-SDR 能精准表示重构的信号的质量。

从计算原理方面，SI-SDR 首先计算原始信号的功率，得到估计信号与原始信号的内积，再计算估计信号在原始信号方向上的投影，算出估计信号与投影的差值作为噪声部分。分别计算投影功率和噪声功率，借助对数运算获得 SI-SDR 值。该值越高，表明估计信号与原始信号在方向上的吻合度越高，算法对原始语音信号的保留越完整，失真越小，性能越出色。

比如在一个语音增强实验中，经过增强处理后的语音与原始干净语音相比，SI-SDR 值若达到了 15dB，相较于未进行增强时的 5dB 大小，该算法有效降低了噪声干扰，使语音信号更接近原始状态，减少了失真。

客观语音质量评估（PESQ）：主观感知

PESQ^[18], 是一种客观的、全参考的语音质量评估方法, 在原始信号与退化信号对比中, 该指标能精准预测人类主观听觉感知下的语音质量。例如语音在传输、编码、解码等环节易受各种因素影响而产生质量劣化, 那么 PESQ 能捕捉这些变化, 并将其转化为量化评分。

其工作原理基于对语音信号的声学特性、人耳听觉感知特性等多方面因素进行综合建模。从较低的语音物理特征（频率响应、时域特性），到高层的听觉感知层面（响度、音色、语音流畅性）其数值范围大小是 0.5~4.5。

短时客观可懂度指标（STOI）：语音可懂度

STOI^[19] 关注衡量被处理语音与干净语音在短时间尺度内时间包络的相关性, 评估语音的可懂度与清晰度。在语音交流中, 时间包络里表示着关键的语音特征与节奏信息, 这些信息的保留程度直接影响听者能否准确理解语音内容。

计算时, 先对原始语音和处理后语音进行短时帧的划分, 提取出每一帧的时间包络特征值, 之后计算两者在各个帧上的相关系数, 最后, 对所有帧的相关系数取平均值得出 STOI 值。STOI 值介于 0 到 1 之间, 越接近 1, 表明处理后的语音时间包络与原始语音越契合, 语音可懂度越高, 听者能捕捉到语音中的词汇、语句等信息; 反之, 若 STOI 值较低, 语音可能模糊不清、断续不连贯, 很难准确分辨语音内容。

综上所述, SI-SDR、PESQ、STOI 这三种音频质量评价指标各有侧重、互相补充。SI-SDR 从信号失真角度, 量化语音分离和增强的效果; PESQ 为主观听感层面, 评估语音质量的优劣; STOI 关注语音可懂度。本次实验的研究内容是 AHS, 更多关注的是信号差异和质量, 所以将使用 SI-SDR、PESQ 两项指标来综合衡量模型性能。

4. 实验组织

本部分内容将着手组织实验，探究不同的网络模型，不同的帧长（输入特征量）和激活函数对啸叫抑制的影响。对于所有语音信号全部为 16Khz 采样率，使用帧长大小为 256，时长为 16ms 的短时傅里叶变换技术进行处理。关于输入特征的构建，不同的神经网络架构下提取方式略有差异，另外，输入特征会附加前 L 帧的数据，用于获取更多信息。训练集和验证集总共使用 450 条音频数据，进行分帧重组后的总样本数在 20 万以上；测试集使用音频共 50 条，其生成特性和数据相对于训练集独立。

实验选取两种经典的神经网络结构：MLP 和 RNN，对于 MLP，我们将前 L 帧的输入样本组合串联形成输入特征，例如 $K=258$ 的特征，其样本输入就是形状为 $(B, L * K)$ 大小的向量，输出则是形状为 (B, K) 的向量。对于 RNN 来说，其输入形状则是 (B, T, K) ，其中 T 代表时间步，即 L 值，B 是批量大小，对于 $K=258$ ，L 为 3 的样本，其网络输入为 $(B, 3, 258)$ 输出则是 $(B, 1, 258)$ 。

实验参数设置如下：

模型训练统一使用 10 个循环，批量大小为 20，模型在单块 GPU 上训练，使用 PyTorch 框架，损失函数使用均方差函数（MSE），优化函数统一使用 Adam 函数，学习率保持在 $1e-4$ 大小。

激活函数实验：

在设定 $L=3$ 后，固定网络结构，依次使用 Sigmoid，ReLU 和 ELU 激活函数来进行对比，以评估不同的激活函数对网络的影响效果。

帧长实验流程：

- 1, L 设置为 (1~5)，输入由当前帧和前 L 帧组成，验证不同的帧长对模型性能的影响。
- 2, 在相同的 L 值下，比较 MLP 和 RNN 的两种训练架构进行比对。
- 3, 统计测试集中的每条音频，计算并记录相关指标以量化实验。

评价指标与结果分析：

通过对比不同帧长和激活函数下的测试信号的平均 SI-SDR 与 PESQ 值，量化各种因素对实验结果的影响。

5. 实验结果

首先，在不经任何方法处理前，我们先对测试集中的语音数据进行指标评估，测得平均 SI-SDR 值为-9.60，平均 PESQ 值为 1.232。

5.1 实验数据记录

5.1.1 激活函数实验结果

本部分实验使用固定使用前向帧长 L 为 3 帧，网络结构选择 MLP，测试变量使用 Sigmoid, ReLU 和 ELU 激活函数来进行实验，分别测量各类网络的对应指标值，结果如下表所示：

表 2 不同激活函数下的模型训练指标

	SI-SDR	PESQ
未处理	-9.60	1.232
Sigmoid	1.91	1.27
ReLU	3.05	1.36
ELU	3.40	1.29

根据上表进行综合对比，ReLU 函数再 PESQ 指标明显优于其他激活函数，反应了 ReLU 激活函数能对语音信号的主观感知有更好的表现。这可能是由于 ReLU 函数的稀疏激活特性能够过滤冗余的噪声特征，强化并传递高频部分的语音成分，这对于主观听觉感受有所提升。而对应的 SI-SDR 值和 ELU 之间的差异较小，这表明两者在信号重构部分的客观保真度上是接近的。ELU 虽然通过负数区间的指数平滑来避免了梯度的突变，但这并没有显著提升语音分离的物理精度。因此，综合模型性能和计算效率来看，后续实验选用 ReLU 作为基础的激活函数，后续实验将基于此选择合适的前向帧长进行实验。

5.1.2 帧长实验结果

本部分实验测试在不同的帧长 L 下，将 MLP 和 RNN 进行对比实验，其他参数如激活函数统一为 ReLU，优化算法使用 Adam。实验结果如下表所示。

表 3 不同帧长 L 下的模型训练指标

模型	MLP		RNN	
指标	SI-SDR	PESQ	SI-SDR	PESQ
未处理	-9.60	1.232	-9.60	1.232
L = 1	2.62	1.330	2.99	1.363
L = 2	3.09	1.361	3.71	1.399
L = 3	3.14	1.387	4.00	1.403
L = 4	3.09	1.370	4.12	1.378
L = 5	3.00	1.384	4.14	1.399

5.2 实验数据分析

将表 3 不同帧长 L 下的模型训练指标中的数据结果进行可视化得到了以下图示：




图 9 不同帧长的模型指标

观察以上图可以得知：

从总体趋势来看，两种模型随着帧长 L 的增加，SI-SDR 值在整体上是呈现先增加后保持平稳的趋势，对于 MLP 而言，其 L 达到 3 时能达到最大的 SI-SDR 值，与 RNN 的变化趋势类似。这说明随着输入数据量的增加，模型能够利用更多的上下文信息来提升其输出语音的质量和可懂度，从而提升性能。另一方面，这也印证了啸叫的信号产生过程中反馈信号与原始信号的耦合过程，更多的帧长代表模型能够更精细的建立映射模型。

比较不同模型，可以发现 RNN 在所有的帧长下的 SI-SDR 和 PESQ 都优于 MLP，从 $L=1$ 到 $L=5$ ，RNN 的所有指标都高于 MLP，这主要说明了 RNN 作为特化了记忆能力的模型，能对时间序列相关数据有更好的拟合程度，其能更好地处理藏在帧中的时间序列信息。

再者考虑到前 L 帧长对模型的影响，可以发现 MLP 对帧长的敏感程度较低，随着帧长的增大，MLP 的性能变化幅度小，甚至会小幅下降，这主要是因为 MLP 模型结构难以处理长序列的信息，这限制了其性能。而对于 RNN 来说，帧长的增加则能增强其性能。而 PESQ 的异常下降则说明，随着帧长的增加，无用信息的占比增大会导致模型性能下降。

5.3 啸叫抑制效果

分析以上实验结果，我们选择使用 RNN 网络的最优参数（选用前向帧长为 3，优化算法选用 Adam，学习率为 $1e-4$ ，训练 10 个 epoch，批量大小为 20）来进行预测推理，将重构生成的信号的时频图画出来进行分析。

原始的语音数据信号的时域表示和时频表示如下图所示




图 10 干净语音的时域图和时频图

时频图能表示语音的能量分布情况，可见原始的信号在低频率下的能量分布均匀，没有出现高能量点。

通过啸叫模拟的啸叫语音的表示如下图所示：




图 11 啸叫语音的时域表示和时频表示

首先，从时域图中可以明显看到经过处理后的信号出现了异常的波形，这就是信号中啸叫的表现形式，而从时频图中可以发现中该啸叫信号在频率 4000Hz 左右有一段异常的高能量点。这就是对应脉冲响应下的啸叫频率点，音频在此频段出现了正反馈，因此出现了啸叫。

而经过 RNN 的预测处理后，我们获得了经过重构的信号表示，如下图表示：




图 12 预测语音的时域表示和时频表示

经过 RNN 的处理后，原始信号的啸叫频率点能量被消除了，因此该模型达到了抑制啸叫的功能要求，但是可以发现经过处理后的数据，其时频图与原始信号的时频图有明显不同，这显然说明，模型损坏了原有的音频音质，这既有模型对信号的预测差异，也有信号重构过程中的损失。因此现有的模型仍需要进行改进完善，以达到更好的实验结果。

6. 结语

在本文中，我们将深度学习技术引入声学啸叫抑制（AHS）领域，鉴于深度学习技术在其他声学领域如语音识别和语言分离等领域的成功。经过理论分析和数学建模，我们将啸叫抑制视作与语音分离类似的监督问题，从而引入这样的一项想法：通过适当的特征提取和网络结构，提取麦克风中的目标语音，削减反馈信号和噪音。在尝试了多种特征工作和网络结构后，实验结果表明了所做工作的有效性。

6.1 总结工作

本文中，个人主要进行了以下的工作内容：

1. 为了描述啸叫现象，本文构建了一个单通道的啸叫系统的数学模型，通过分析啸叫产生的数学原理和信号特点，引入深度学习的技术来探究声学啸叫抑制问题，研究了将啸叫抑制视作一个类似语音分离问题的方案。
2. 为了解决啸叫数据稀少的问题，本文依据啸叫数学模型搭建了一个用以模拟啸叫的仿真程序，并据此生成了具备一定随机性的啸叫数据，为深度学习模型的搭建构筑了数据基础。
3. 针对啸叫抑制问题的数据特点选择了对应网络结构，进行了模型搭建工作和训练验证，评估了各类参数和部件。选择了较适用于啸叫抑制的相关部件和参数，包括模型选择和特征工程等，使得神经网络能够对输入的啸叫信号进行处理以获得重构的信号，证明了方案的可行性。

6.2 下一步工作与展望

本文针对啸叫现象进行抽象建模，再经过模拟生成和模型训练，得到了重构信号，验证了使用深度学习解决 AHS 问题的可行性。但由于能力限制，此项研究还远远未被完善，为了达到能与传统方法，尤其是与 AFC 相近的效果，特征工程，网络结构，和推理流程都需要进行改进完善，因此未来的工作可以包括以下内容：

(1) **特征改进**：本文使用的特征是 STFT 复数值系数，较为简单。且其数值范围较大，难以归一化，对模型的训练效果影响较大，为了从音频中提取对模型更友好，更易训练的特征，可以考虑使用不同的特征工程，可以提取包括基于听觉的特征（MFCC），归一化功率谱（LPS）或相关性矩阵等特征，以获取更适合网络的信息。

（2）**网络结构修改**：本文所使用的网络结构都是比较简单的模型结构，这类单一的网络结构往往难以拟合现实数据，因此下一步工作可以是修改网络结构，使用更加复杂的复合结构，使用包括多层卷积和自注意力机制的网络等，同时也可以参考相似领域的模型进行修改来适应本问题。

（3）**启停设置**：对于时域信号来说，进行傅里叶变换和逆变换会损失部分信息，增加噪音等，所以在实验初期会出现模型处理后的指标低于原始指标的情况，这是因为在低增益，没有产生啸叫的情况下对信号进行变换重构会降低信号质量。所以可以增加一个啸叫识别模块，在检测到啸叫时才启动模型预测。

（4）**多通道模型**：现实场景下大多数扩音系统不只是单通道系统，所以为了探索方案的实用性，可以将该方案扩展到多通道模型下。

（5）**硬件实现与部署**：为了将所提出的方案进行实用化，硬件实现和部署是必须考虑的一个问题。下一步工作需要考虑降低模型的参数量，减少计算量并尝试将模型部署到特定的设备或平台上。

参考文献

- [1] 周璐.影响自适应反馈抵消啸叫抑制算法性能的声学因素分析[D]. 南京大学, 2012.
- [2] 杨阳. 声学系统中反馈抑制器的研究和 DSP 实现[D]. 广州大学, 2016.
- [3] 赵明. 啸叫检测与抑制扩声系统设计[D]. 西北大学, 2018.
- [4] 王凤森.扩声系统中啸叫抑制算法的研究[D]. 五邑大学, 2020.
- [5] 甘华国.基于深度学习的音频啸叫处理方法研究[D]. 广州大学, 2021.
- [6] Abe R. Howling suppression device and howling suppression method[P]. US: US7295 670 B2, 2007.
- [7] Edgar Berdahl and Dan Harris, "Frequency shifting for acoustic howling suppression," in Proceedings of the 13th International Conference on Digital Audio Effects, Graz, Austria, 2010, vol. 610.
- [8] W Loetwassana, R Punchalard, A Lorsawatsiri, J Koseeyaporn, and P Wardkein, "Adaptive howling suppressor in an audio amplifier system," in 2007 Asia-Pacific Conference on Communications. IEEE, 2007, pp. 445–448.
- [9] Toon van Waterschoot and Marc Moonen, "Comparative evaluation of howling detection criteria in notch-filter-based howling suppression," Journal of the audio engineering society, vol. 58, no. 11, pp. 923–940, 2010.
- [10] Guozheng Wang, Quanli Liu, and Wei Wang, "Adaptive feedback cancellation with prediction error method and howling suppression in train public address system," Signal Processing, vol. 167, pp. 107279, 2020.
- [11] Hao Zhang, Ke Tan, and De Liang Wang, "Deep learning for joint acoustic echo and noise cancellation with nonlinear distortions," in INTERSPEECH, 2019, pp. 4255–4259.
- [12] H. Zhang, M. Yu and D. Yu, "Deep Learning for Joint Acoustic Echo and Acoustic Howling Suppression in Hybrid Meetings," 2023 IEEE Automatic Speech Recognition and Understanding Workshop (ASRU), Taipei, Taiwan, 2023, pp. 1-7
- [13] Shimin Zhang, Yuxiang Kong, Shubo Lv, Yanxin Hu, and Lei Xie, "FT-LSTM based complex network for joint acoustic echo cancellation and speech enhancement," arXiv preprint arXiv:2106.07577, 2021.

- [14] H. Zhang, M. Yu and D. Yu, "Deep AHS: A Deep Learning Approach to Acoustic Howling Suppression," ICASSP 2023 - 2023 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP), Rhodes Island, Greece, 2023, pp. 1-5
- [15] Jont B Allen and David A Berkley, "Image method for efficiently simulating small-room acoustics," The Journal of the Acoustical Society of America, vol. 65, no. 4, pp. 943–950, 1979.
- [16] Jiayu Du, Xingyu Na, Xuechen Liu, and Hui Bu, "Aishell 2: Transforming mandarin asr research into industrial scale," arXiv preprint arXiv:1808.10583, 2018.
- [17] Jonathan Le Roux, Scott Wisdom, Hakan Erdogan, and John R Hershey, "SDR–half-baked or well done?," in 2019 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2019, pp. 626–630.
- [18] Antony W Rix, John G Beerends, Michael P Hollier, and Andries P Hekstra, "Perceptual evaluation of speech quality (PESQ)-a new method for speech quality assessment of telephone networks and codecs," in 2001 IEEE International Conference on Acoustics, Speech, and Signal Processing (ICASSP). IEEE, 2001, vol. 2, pp. 749–752.
- [19] Taal C H, Hendriks R C, Heusdens R, et al. An Algorithm for Intelligibility Prediction of Time–Frequency Weighted Noisy Speech[J]. IEEE Transactions on Audio Speech & Language Processing, 2011, 19(7):2125-2136.

声 明

本人声明所呈交的学位论文是本人在导师指导下进行的研究工作及取得的研究成果。据我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得四川大学或其他教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示谢意。

本学位论文成果是本人在四川大学读书期间在导师指导下取得的，论文成果归四川大学所有，特此声明。

作者签名：蒲晓阳

导师签名：[Signature]

2025 年 5 月 22 日

学位论文使用授权书

本学位论文作者完全了解四川大学有关保留、使用学位论文的规定，同意学校保留并向国家有关部门或相关机构送交论文的原件、复印件和电子版，允许论文被查阅和借阅。本人授权四川大学将本学位论文的全部或部分内容编入有关数据库进行信息技术服务，可以采用影印、缩印或扫描等复制手段保存、汇编学位论文，并用于学术活动。

（涉密学位论文在解密后适用于本授权书）

作者签名：蒲晓阳

导师签名：[Signature]

2025 年 5 月 22 日

四川大学本科毕业论文 AI 工具使用声明

本人声明，在撰写题目为《音频增强系统啸叫智能检测和抑制方法》的本科毕业论文过程中，对 AI 工具的使用情况如下：

一、使用的 AI 工具及使用目的

序号	AI 工具	使用目的
1	DeepSeek	资料检索辅助
2	Kimi	相关知识检索

二、使用程度说明

序号	章节	AI 工具	使用方式	处理方式
1	正文第一章绪论：研究背景与意义	DeepSeek	输入相关问题获取回答、进行相关论文的检索阅读。	仔细阅读理解与归纳，自行阅读相关文献来核对相关内容、结合研究进行适配，独立组织完成论文。
2	正文第一章绪论：研究背景与意义	Kimi	输入相关问题获取回答、进行相关论文的检索阅读。	仔细阅读理解与归纳，自行阅读相关文献来核对相关内容、结合研究进行适配，独立组织完成论文。

在论文的正文第一章绪论：研究背景与意义 使用了上述 AI 工具。使用方式为 输入相关问题获取回答、进行相关论文的检索阅读。

本人对 AI 工具提供的内容进行了仔细阅读理解与归纳整理相关知识，自行阅读相关文献来核对相关内容、结合自身的研究进行适配，独立组织完成论文，以确保论文内容符合学术要求及本人的研究思路。

三、原创性与责任声明

本人确认，尽管使用了上述 AI 工具，但论文整体的研究思路、核心观点、论证过程及最终结论均为本人独立思考与研究的成果。论文中引用 AI 工具生成内容之处，均已按照学校规定的学术规范进行了明确标注。

若论文因 AI 工具使用不当或未按要求标注等原因出现学术不端问题，本人愿意承担全部责任。

学生签名：潘晓阳

指导老师签名：张书

2025 年 5 月 22 日

致谢

即将完成本科毕业的最后旅程，回望来路，我收获了许多知识，也得到了许多教训，这段路充满了挑战与风景，在结束这段路前，我要向所有给我支持，指导和帮助的人表示谢意。

首先我要感谢冯老师，作为我的指导老师，在与他第一次相见时我便学到了许多，在给我指导选题和开题汇报时就给了我许多帮助，让我对项目有了更细致的了解。更加感谢的是在我的相关工作陷入迷茫困惑，逐渐懈怠之时，能给我及时给予提醒与敲打，给我指明了方向，让我得以及时完成此次工作。

我还要感谢我的学校，老师和同学们，学校给了我默默的关怀，老师们在我学习和生活中给了我许多帮助，同学们陪伴了我整个大学时光，非常感谢。

最后我要感谢我的父母，感谢父母的无私付出，没有他们的支持和陪伴，我没有机会踏进这座校园，进行更高层次的学习，了解更广阔的世界。